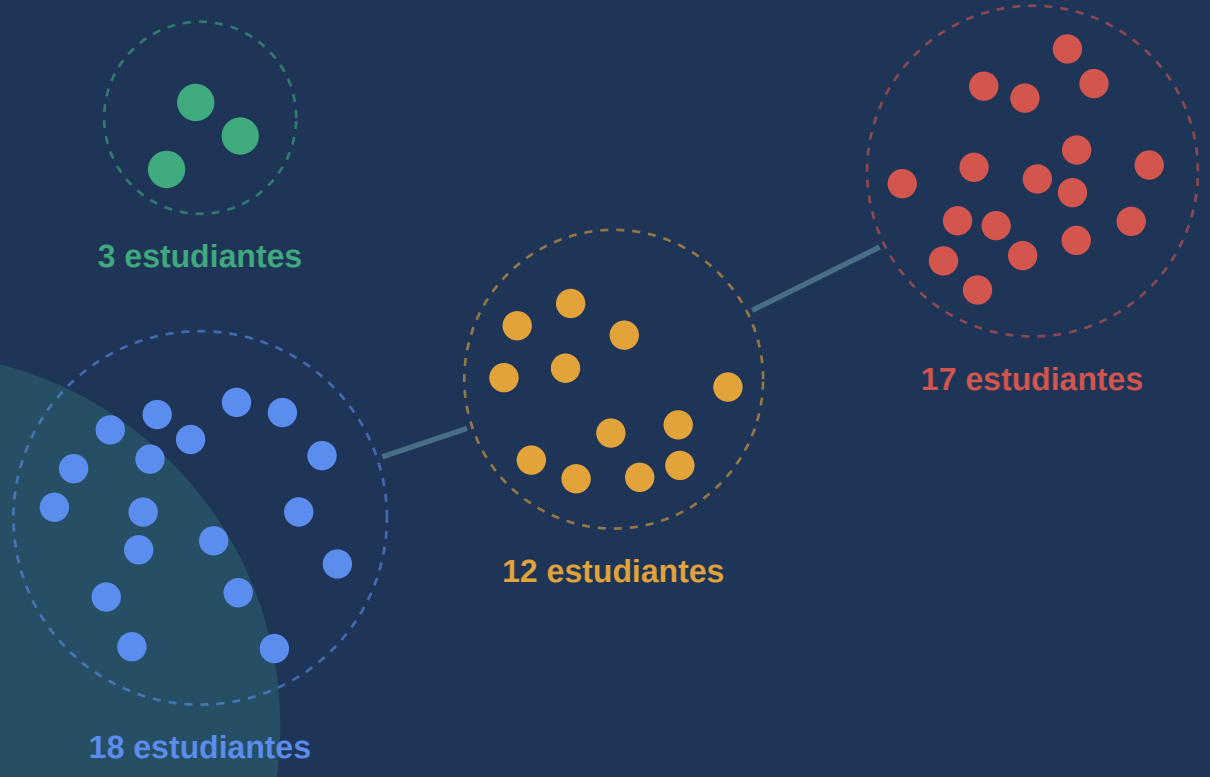
INFORME TÉCNICO | TRABAJO FINAL

Segmentación de estudiantes con K-Means

Descripción del procedimiento y análisis del agrupamiento de estudiantes según edad, horas de estudio y promedio académico



PLANTEAMIENTO

Segmentación de estudiantes con K-Means

Se dispone de un conjunto de datos de cincuenta estudiantes, descritos por tres variables: edad, horas de estudio y promedio académico. Se busca identificar, mediante un algoritmo de agrupamiento, perfiles diferenciados de estudiantes que permitan comprender cómo se relacionan estas características entre sí. Los datos utilizados son simulados.

Objetivo

Construir un programa en Python que utilice el algoritmo de clustering K-Means para segmentar a los estudiantes en cuatro grupos según su edad, sus horas de estudio y su promedio académico.

Tareas

1. Cargar los datos de los estudiantes en un DataFrame.
2. Estandarizar las variables para ponerlas en una escala común.
3. Aplicar K-Means con 4 clusters.
4. Asignar a cada estudiante el grupo al que pertenece.
5. Visualizar los resultados en un gráfico de dispersión.

RESOLUCIÓN

Segmentación mediante K-Means

Procedimiento y análisis de resultados · Estudiantes (datos simulados)

Descripción general. El presente trabajo aplica el algoritmo K-Means, una técnica de aprendizaje automático no supervisado, para clasificar a 50 estudiantes en cuatro segmentos según su edad, sus horas de estudio y su promedio académico. Los datos utilizados son simulados, por lo que los resultados tienen carácter ilustrativo.

Síntesis de resultados

18
Jóvenes · bajo promedio
estudiantes · grupo azul

17
Mayor edad · alto promedio
estudiantes · grupo rojo

12
Edad intermedia · promedio medio
estudiantes · grupo naranja

3
Jóvenes · alto promedio
estudiantes · grupo verde

Cómo funciona

1 Herramientas

El análisis se desarrolló en Python, lenguaje de programación de uso extendido en ciencia de datos. Se emplearon bibliotecas especializadas para tres tareas: organizar la información en formato tabular, aplicar el algoritmo de agrupamiento y representar gráficamente los resultados.

2 Los datos

Se trabajó con un conjunto simulado de 50 estudiantes, cada uno descrito por tres variables: edad, horas de estudio y promedio académico. Los valores se organizaron en una tabla que permite su procesamiento sistemático; por ejemplo, un estudiante de 26 años con 8 horas de estudio presenta un promedio de 9,11.

3 Estandarización

Antes del agrupamiento, los valores se estandarizaron: se expresaron en una escala común en la que el promedio equivale a cero y cada dato indica cuánto se aleja de él. Este paso es fundamental en este caso, porque las tres variables se miden en unidades distintas (años, horas y puntos de calificación); sin él, la variable de mayor rango tendría más influencia sobre el resultado.

4 El algoritmo K-Means

K-Means es un método de aprendizaje no supervisado: no parte de categorías predefinidas, sino que las identifica a partir de la similitud entre los datos. Se fija el número de grupos (K = 4), se asigna cada estudiante al centro de grupo más cercano y se recalculan los centros como el promedio de cada grupo. El proceso se repite hasta que la asignación se estabiliza. Finalmente, cada grupo se identificó con un color en el gráfico y se interpretó a partir de las características promedio de sus integrantes.

Descripción de los datos

Variable	Mínimo	Máximo	Promedio
Edad (años)	21	60	39,54
Horas de estudio	2	15	7,86
Promedio académico	1,00	9,11	5,52

Resultados obtenidos

Segmento	Estudiantes	Edad (años)	Horas de estudio	Promedio académico
● **Jóvenes con alta dedicación y bajo promedio**	18	**28,9** (22–35)	**11,6** (9–15)	**2,67** (1,00–4,45)
● **Mayor edad, baja dedicación y alto promedio**	17	**51,9** (42–60)	**3,8** (2–5)	**7,84** (6,12–9,00)
● **Edad intermedia y desempeño medio**	12	**41,5** (36–47)	**6,9** (6–9)	**5,77** (4,00–8,50)
● **Jóvenes con alta dedicación y alto promedio**	3	**25,3** (21–29)	**12,3** (8–15)	**8,46** (7,27–9,11)

Promedio de cada grupo y, entre paréntesis, rango (mínimo–máximo). Las denominaciones de los segmentos corresponden a la interpretación del análisis.

Análisis de resultados

Jóvenes con alta dedicación y bajo promedio (azul). Es el grupo más numeroso (18 estudiantes), con edades de 22 a 35 años, entre 9 y 15 horas de estudio y los promedios más bajos (2,67).

Mayor edad, baja dedicación y alto promedio (rojo). Diecisiete estudiantes de 42 a 60 años que estudian entre 2 y 5 horas y alcanzan un promedio de 7,84.

Edad intermedia y desempeño medio (naranja). Doce estudiantes de 36 a 47 años, con 6 a 9 horas de estudio y un promedio de 5,77, en una posición intermedia en las tres variables.

Jóvenes con alta dedicación y alto promedio (verde). Tres estudiantes de 21 a 29 años, con 12,3 horas de estudio y un promedio de 8,46: es el único segmento en que una alta dedicación coincide con un alto rendimiento.

Relación entre variables. En estos datos, la edad se asocia de forma inversa con las horas de estudio (correlación de −0,92) y directa con el promedio (0,71); las horas de estudio, a su vez, se asocian de forma inversa con el promedio (−0,73). Son relaciones propias de los datos simulados y no deben generalizarse.

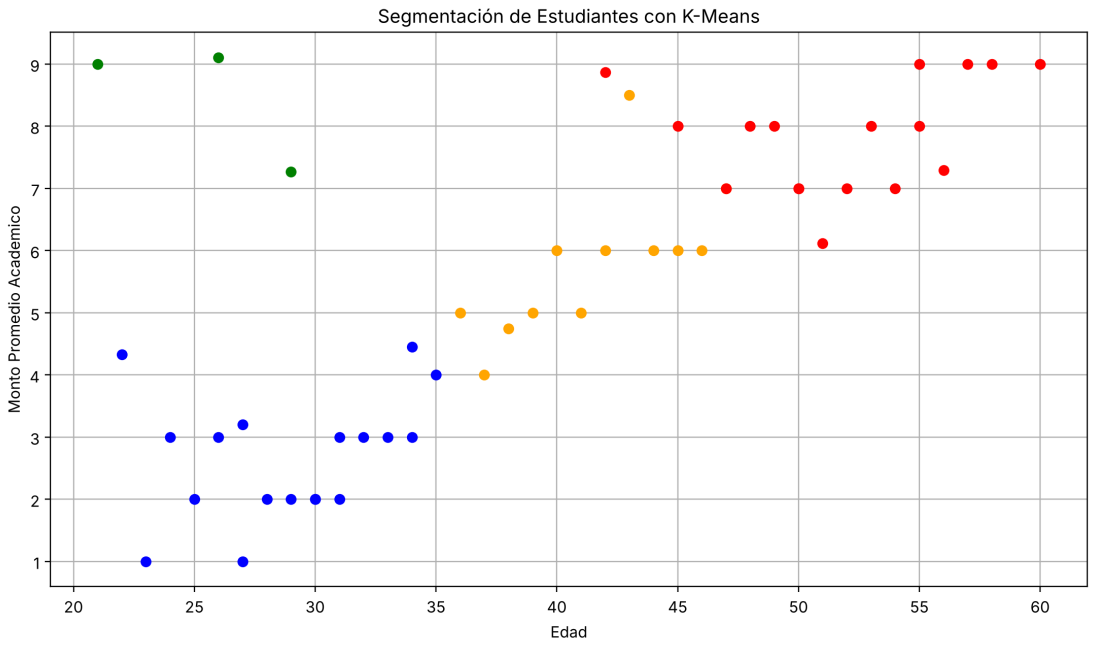


Figura 1. Gráfico de dispersión de los estudiantes según edad y promedio académico, diferenciados por segmento: azul (jóvenes con bajo promedio), rojo (mayor edad y alto promedio), naranja (edad intermedia) y verde (jóvenes con alto promedio). El gráfico representa dos de las tres variables utilizadas en el agrupamiento.

Limitaciones del análisis

Datos simulados. Los valores no provienen de un relevamiento real, por lo que los resultados son ilustrativos y no permiten extraer conclusiones sobre estudiantes reales.

Tamaño de la muestra. Con 50 estudiantes, el segmento verde reúne solo a tres casos, por lo que su interpretación debe tomarse con cautela.

Visualización parcial. El gráfico bidimensional representa la edad y el promedio académico; las horas de estudio participan en el agrupamiento pero no se observan en la figura, por lo que algunos grupos parecen superponerse.

Selección del número de grupos. K-Means exige definir de antemano la cantidad de grupos; en este caso se fijó en cuatro. Existen criterios para fundamentar esa decisión, como el método del codo o el coeficiente de silueta, que en este agrupamiento toma un valor de 0,47, indicativo de una separación moderada entre los grupos.

Conclusiones

La aplicación de K-Means permitió segmentar a los 50 estudiantes en cuatro perfiles diferenciados: jóvenes con alta dedicación y bajo promedio, que constituyen el grupo más numeroso; estudiantes de mayor edad con baja dedicación y alto promedio; un grupo de edad y desempeño intermedios; y un grupo reducido de jóvenes que combinan alta dedicación y alto promedio. El resultado muestra que el algoritmo es capaz de identificar perfiles a partir de varias variables a la vez. No obstante, al tratarse de datos simulados, los perfiles obtenidos deben interpretarse como un ejercicio ilustrativo y no como evidencia sobre estudiantes reales.